Implementasi Latent Dirichlet Allocation (LDA) untuk Analisis Topik pada Data Teks Ulasan Aplikasi Gojek

Ilham Khadafi
Program Studi Statistika, Universitas Indonesia
ilham.khadafi@ui.ac.id

Identitas:

NIM 2306260952
Kelas A

Kata Kunci:

Topic Modeling
LDA
Analisis Topik
Ulasan Aplikasi
NLP

ABSTRAK

Penelitian ini berfokus pada implementasi Latent Dirichlet Allocation (LDA) untuk melakukan analisis topik pada data ulasan pengguna aplikasi Gojek yang bersumber dari platform Kaggle. Ulasan pengguna pada toko aplikasi merupakan sumber data tidak terstruktur yang kaya akan informasi, namun sulit dianalisis secara manual dalam skala besar. Melalui serangkaian tahap preprocessing teks bahasa Indonesia, yang mencakup case folding, pembersihan karakter, penghapusan stopwords menggunakan kamus Sastrawi dan kamus kustom (867 kata), serta stemming, sebanyak 87.930 ulasan (39,1%) berhasil diproses dari total 225.000 data awal, dengan 30.000 ulasan digunakan sebagai sampel pemodelan. Model LDA dengan parameter K=5 berhasil mengidentifikasi lima topik utama dalam ekosistem layanan Gojek, yaitu: (1) Promo & Diskon, (2) Masalah Akun & GoPay, (3) Kepuasan Layanan, (4) Layanan GoFood & Driver, dan (5) Pembayaran & GoPay Later. Hasil analisis menunjukkan bahwa topik Layanan GoFood & Driver merupakan yang paling dominan (26,7%), sementara topik Kepuasan Layanan menunjukkan korelasi kuat dengan ulasan bintang 5 (40,0%). Penelitian ini mendemonstrasikan bahwa implementasi LDA efektif dalam mengekstraksi wawasan tersembunyi dari ulasan pengguna untuk mendukung pengambilan keputusan strategis berbasis data bagi pengembang aplikasi.

Link Code Github: https://github.com/hamkhadafi/gojek-reviews-topic-modeling

1. PENDAHULUAN

Perkembangan platform digital di Indonesia telah mendorong pertumbuhan signifikan dalam jumlah ulasan pengguna yang dipublikasikan di toko aplikasi seperti Google Play Store. Gojek, sebagai salah satu perusahaan teknologi terbesar di Asia Tenggara dengan ekosistem layanan yang mencakup transportasi, pesan-antar makanan, pembayaran digital, dan berbagai layanan lainnya, menerima jutaan ulasan dari penggunanya setiap tahun. Ulasan ini merupakan bentuk umpan balik organik yang sangat berharga, namun karena bersifat tidak terstruktur dan sangat bervariasi, analisis manual menjadi tidak efisien dan tidak skalabel.

Analisis teks berbasis pemrosesan bahasa alami (Natural Language Processing / NLP) menawarkan solusi untuk mengekstrak wawasan bermakna dari data tekstual skala besar secara otomatis. Salah satu pendekatan yang paling banyak digunakan dalam analisis teks tidak berlabel adalah topic modeling, yaitu metode pembelajaran tanpa pengawasan (unsupervised learning) yang bertujuan menemukan topik-topik tersembunyi dalam kumpulan dokumen berdasarkan pola kemunculan kata [1].

Latent Dirichlet Allocation (LDA), yang diperkenalkan oleh Blei et al. [2], merupakan model probabilistik generatif yang menjadi standar de facto dalam topic modeling. LDA mengasumsikan bahwa setiap dokumen merupakan campuran dari beberapa topik, dan setiap topik merupakan distribusi probabilistik atas kosakata. Pendekatan ini sangat sesuai untuk menganalisis ulasan pengguna yang sering kali mencakup beberapa aspek sekaligus dalam satu kalimat.

Penelitian ini bertujuan untuk: (1) mengidentifikasi topik-topik utama yang dibicarakan pengguna dalam ulasan aplikasi Gojek; (2) menganalisis distribusi topik tersebut; dan (3) mengkaji hubungan antara topik dengan rating yang diberikan pengguna. Hasil penelitian diharapkan dapat memberikan pemahaman mendalam tentang aspek-aspek layanan yang menjadi perhatian utama pengguna Gojek, sehingga dapat mendukung pengambilan keputusan strategis berbasis data.

2. DATA DAN METODE

2.1. Data

Data yang digunakan dalam penelitian ini adalah kumpulan ulasan pengguna aplikasi Gojek berbahasa Indonesia yang diperoleh dari platform repositori data sumber terbuka Kaggle (dengan judul dataset "Gojek App Reviews Bahasa Indonesia"). Dataset ini merekam ulasan pengguna untuk versi aplikasi mulai dari V4.0.0 hingga V4.9.3. Data yang digunakan tersedia dalam format Comma-Separated Values (CSV) dengan nama file GojekAppReviewV4_0_0-V4_9_3_Cleaned.csv yang telah melalui tahap pembersihan awal, menyisakan total 225.000 baris data observasi.

Dataset ini terdiri dari lima atribut utama yang merekam informasi metrik dan deskriptif mengenai ulasan pengguna, sebagaimana disajikan pada Tabel 1.

Table 1. Deskripsi Atribut Dataset Ulasan Gojek

Atribut	Tipe Data	Keterangan
userName	String	Nama pengguna yang memberikan ulasan
content	String	Teks ulasan pengguna (variabel utama analisis)
score	Integer (1-5)	Rating bintang yang diberikan pengguna
at	Datetime	Waktu ulasan diberikan
appVersion	String	Versi aplikasi saat ulasan diberikan

Distribusi rating ulasan menunjukkan ketidakseimbangan yang cukup signifikan: ulasan bintang 5 mendominasi dengan 65,4% (147.055 ulasan), diikuti bintang 1 sebesar 20,1% (45.229 ulasan). Kondisi ini mencerminkan pola umum pada dataset ulasan aplikasi, di mana pengguna cenderung memberikan ulasan saat merasa sangat puas atau sangat tidak puas. Rata-rata panjang ulasan adalah 63,8 karakter atau 10,4 kata per ulasan, menunjukkan bahwa sebagian besar ulasan bersifat singkat dan padat.

2.2. Method

Alur penelitian ini mengikuti empat tahap utama: (1) preprocessing teks, (2) representasi dokumen dalam bentuk matriks, (3) pemodelan topik dengan LDA, dan (4) evaluasi serta interpretasi hasil.

a) Preprocessing Teks

Tahap preprocessing merupakan tahap krusial dalam analisis teks berbahasa Indonesia yang banyak mengandung singkatan, kata tidak baku, dan variasi ejaan. Pipeline preprocessing yang diterapkan adalah sebagai berikut: (1) case folding — konversi teks ke huruf kecil; (2) penghapusan URL, mention, dan hashtag; (3) penghapusan angka dan karakter non-alfabet; (4) penghapusan kata pendek (kurang dari 3 karakter); (5) penghapusan stopwords menggunakan kombinasi kamus Sastrawi dan kamus kustom (total 867 kata); dan (6) stemming menggunakan algoritma Sastrawi untuk mereduksi kata ke bentuk dasarnya [3].

Dari 225.000 ulasan awal, sebanyak 87.930 ulasan (39,1%) memenuhi syarat minimal tiga kata bermakna setelah preprocessing. Ulasan yang terlalu pendek atau tidak mengandung kata bermakna dieliminasi karena tidak berkontribusi pada pemodelan topik.

b) Representasi Dokumen: Document-Term Matrix

Teks yang telah diproses diubah menjadi representasi numerik menggunakan CountVectorizer dari pustaka Scikit-learn [4]. Parameter yang digunakan adalah: max_df = 0,90 (hapus kata yang muncul di lebih dari 90% dokumen), min_df = 10 (hapus kata yang muncul di kurang dari 10 dokumen), max_features = 3.000, dan ngram_range = (1,2) untuk menangkap unigram dan bigram. Hasil akhir adalah Document-Term Matrix (DTM) berukuran 30.000 × 3.000.

c) Penentuan Jumlah Topik Optimal (K)

Penentuan jumlah topik K dilakukan dengan mengevaluasi nilai perplexity untuk berbagai nilai K (3, 4, 5, 6, 7, 8, 10). Perplexity mengukur seberapa baik model probabilistik memprediksi sampel baru — semakin rendah nilainya, semakin baik model secara matematis. Selain pertimbangan kuantitatif, keputusan pemilihan K juga mempertimbangkan interpretabilitas topik secara domain (domain-driven decision).

d) Latent Dirichlet Allocation (LDA)

LDA merupakan model probabilistik generatif dengan asumsi bahwa setiap dokumen d merupakan campuran dari K topik dengan distribusi Dirichlet sebagai prior. Secara formal, proses generatif LDA dapat dirumuskan sebagai berikut [2]:

$$p(\beta,\ \theta,\ z,\ w)\ =\ \prod^{K}_{i=1} p(\beta_i|\eta) \cdot \prod^{D_d}_{=1} p(\theta^d|\alpha) \cdot \prod^{N}_{=1} p(z^d, |\theta^d) \cdot p(w^d, |\beta_1: ,\ z^d,) \quad \ldots \quad (1)$$

di mana α adalah parameter konsentrasi distribusi topik per dokumen, η adalah parameter konsentrasi distribusi kata per topik, θ^d adalah distribusi topik untuk dokumen d, β adalah distribusi kata untuk topik k, z^d, adalah penugasan topik untuk kata ke-n pada dokumen d, dan w^d, adalah kata yang terobservasi.

Model dilatih menggunakan metode online variational Bayes dengan parameter max_iter = 30, learning_method = 'online', dan learning_decay = 0,7.

3. HASIL DAN PEMBAHASAN

3.1 Penentuan Jumlah Topik

Evaluasi nilai perplexity untuk berbagai nilai K ditunjukkan pada Gambar 1. Terlihat bahwa nilai perplexity terus meningkat seiring bertambahnya K, dengan nilai terendah pada K=3 (861,7) dan cenderung stagnan pada $K \geq 7$ (~ 1.100). Tidak terdapat titik "siku" (elbow) yang jelas, yang merupakan kondisi umum pada dataset ulasan aplikasi dengan teks pendek [5].

Mempertimbangkan kondisi tersebut, pemilihan K dilakukan secara domain-driven: K=3 terlalu sedikit untuk merepresentasikan keragaman tema pada aplikasi super-app seperti Gojek, sementara $K \geq 7$ menghasilkan topik yang terlalu granular dan sulit diinterpretasi mengingat

rata-rata panjang ulasan hanya 10,4 kata. Oleh karena itu, dipilih K=5 yang menghasilkan perplexity = 992,9 dengan topik-topik yang kohesif dan dapat diinterpretasi secara jelas.

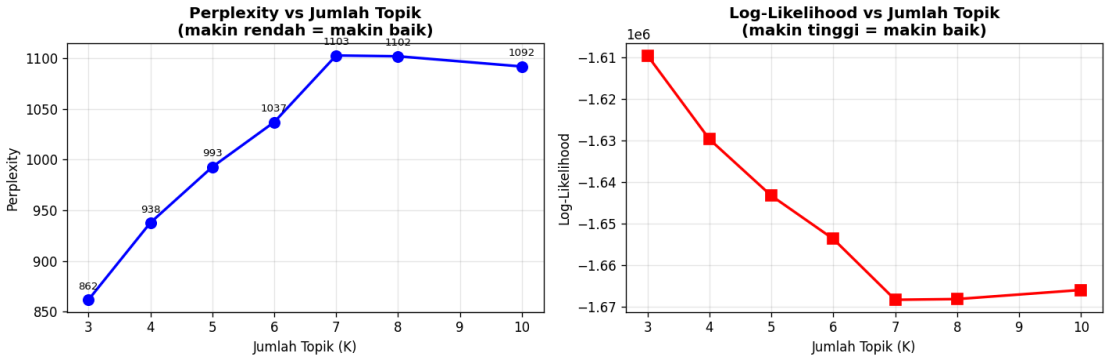

Figure 1. Grafik Perplexity dan Log-Likelihood vs Jumlah Topik K

3.2 Identifikasi Topik

Model LDA dengan K=5 berhasil mengidentifikasi lima topik yang secara semantis kohesif dan berbeda satu sama lain. Gambar 2 menampilkan 10 kata teratas per topik beserta bobot relatifnya, sedangkan Gambar 3 menampilkan visualisasi WordCloud per topik.

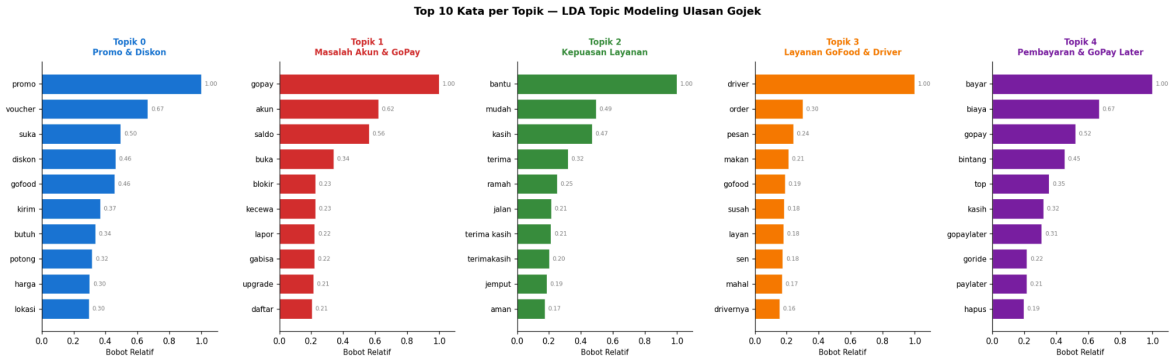

Figure 2. Top 10 Kata per Topik dengan Bobot Relatif

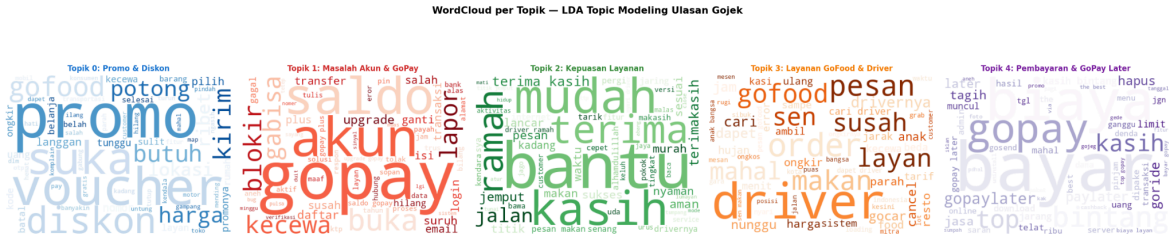

Figure 3. WordCloud per Topik — LDA Topic Modeling Ulasan Gojek

Kelima topik yang ditemukan beserta karakteristiknya disajikan pada Tabel 2.

Table 2. Hasil Identifikasi Topik dan Deskripsinya

Topik	Label	Kata Kunci Utama	Interpretasi
0	Promo & Diskon	promo, voucher, diskon, gofood, kirim, harga, ongkir	Ulasan terkait kebijakan promosi, voucher diskon, harga

			ongkir, dan ketersediaan promo pada layanan GoFood
1	Masalah Akun & GoPay	gopay, akun, saldo, blokir, buka, kecewa, transaksi	Keluhan pengguna terkait masalah teknis pada akun dan dompet digital GoPay, termasuk pemblokiran dan kegagalan transaksi
2	Kepuasan Layanan	bantu, mudah, terima, ramah, nyaman, jalan, aman	Ekspresi kepuasan umum pengguna terhadap kemudahan penggunaan aplikasi dan keramahan layanan
3	Layanan GoFood & Driver	driver, order, pesan, makan, gofood, susah, mahal	Ulasan spesifik terkait pengalaman memesan makanan melalui GoFood dan kinerja mitra driver
4	Pembayaran & GoPay Later	bayar, biaya, gopaylater, bintang, top, tagih, paylater	Keluhan dan ulasan terkait biaya jasa aplikasi, layanan GoPay Later, dan mekanisme pembayaran

3.3 Distribusi Topik

Distribusi dokumen terhadap masing-masing topik dominan ditampilkan pada Gambar 4. Topik 3 (Layanan GoFood & Driver) menjadi topik yang paling banyak dibicarakan (26,7%; 8.011 ulasan), mencerminkan betapa sentralnya layanan pengiriman makanan dalam ekosistem Gojek. Topik 1 (Masalah Akun & GoPay) menempati urutan kedua (20,6%; 6.186 ulasan), mengindikasikan bahwa permasalahan dompet digital merupakan isu utama yang dikeluhkan pengguna.

Topik 4 (Pembayaran & GoPay Later) memiliki proporsi terendah (15,5%; 4.665 ulasan), namun masih signifikan mengingat layanan GoPay Later merupakan fitur yang relatif baru. Distribusi yang cukup merata di antara kelima topik (15,5%–26,7%) menunjukkan bahwa model berhasil mengidentifikasi topik-topik yang benar-benar distinct dan tidak redundan.

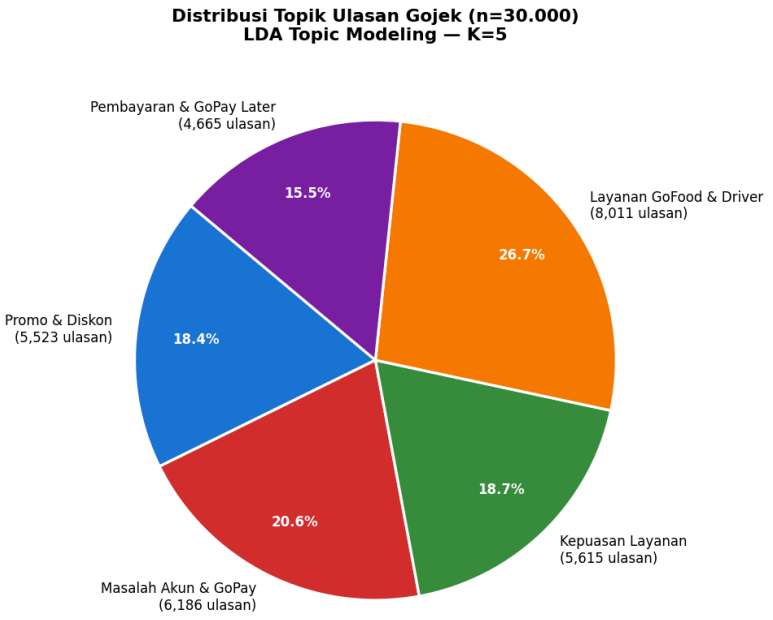

Figure 4. Distribusi Dokumen per Topik (n=30.000 ulasan)

3.4 Hubungan Topik dengan Rating Pengguna

Analisis hubungan antara distribusi topik dan rating bintang disajikan dalam bentuk heatmap pada Gambar 5. Beberapa temuan menarik dapat diidentifikasi:

- Topik 2 (Kepuasan Layanan) memiliki korelasi sangat kuat dengan ulasan bintang 5: sebesar 40,0% ulasan bintang 5 berasal dari topik ini, jauh lebih tinggi dibandingkan dengan proporsinya pada rating rendah (5,1% untuk bintang 1). Ini mengonfirmasi bahwa topik ini memang merepresentasikan sentimen positif.
- Topik 1 (Masalah Akun & GoPay) dan Topik 3 (Layanan GoFood & Driver) mendominasi ulasan bintang 1 dengan proporsi masing-masing 29,3% dan 32,9%, mengindikasikan bahwa kedua topik ini paling banyak mengandung keluhan serius.
- Topik 0 (Promo & Diskon) memiliki distribusi yang relatif merata di semua rating (16,1%–22,8%), menunjukkan bahwa topik promo dibicarakan baik oleh pengguna yang puas maupun yang tidak puas.
- Topik 4 (Pembayaran & GoPay Later) cenderung lebih banyak muncul pada ulasan bintang rendah (16,5% bintang 1) dibandingkan bintang 5 (12,5%), mengindikasikan adanya ketidakpuasan terkait mekanisme pembayaran dan biaya layanan.

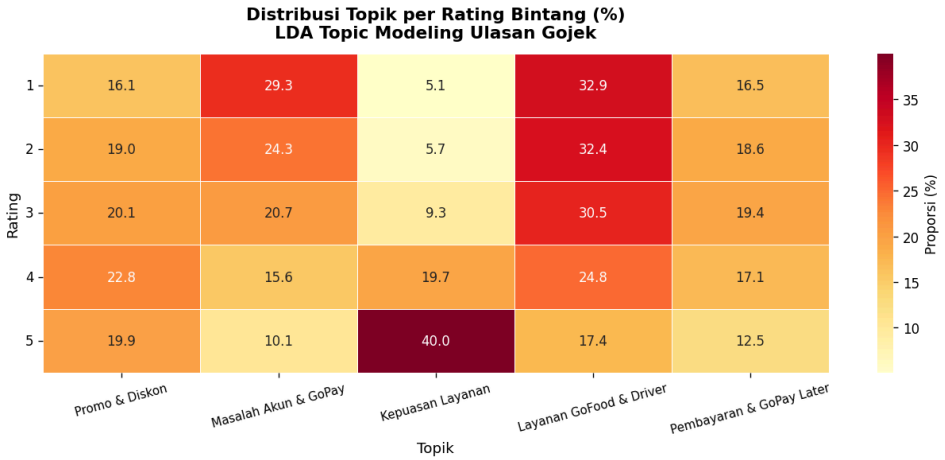

Figure 5. Heatmap Distribusi Topik per Rating Bintang (%)

3.5 Contoh Representatif per Topik

Untuk memvalidasi kualitas topik yang dihasilkan, Tabel 3 menyajikan contoh ulasan representatif dengan probabilitas penugasan topik tertinggi dari setiap topik. Probabilitas penugasan yang tinggi (>0,90) mengindikasikan bahwa model berhasil mengenali pola tematik dengan baik.

Table 3. Contoh Ulasan Representatif per Topik

Topik	Contoh Ulasan	Rating	Prob.
Promo & Diskon	sekarang promo ga bisa di gabung diskon dari resto dan dari voucher promo gofoodnya jadi harus pilih salah satu jadi muahallll	⭐	0.950
Masalah Akun & GoPay	Kapok transfer lewat gopay suruh nunggu 2x24 jam Kalo gagal balikin lagi aja saldo gopay malah di suruh nunggu 2 hari Bikin jengkel kan 2 hari gitu	⭐	0.958
Kepuasan Layanan	Terima kasih Gojek dg adanya aplikasi ini mau kemana saja jadi mudah dan ada rasa aman dan nyaman terima kasih salam sukses Selalu untuk semuanya	⭐⭐⭐⭐⭐	0.947
Layanan GoFood & Driver	Sering gak dapet driver kalau malem order go food padahal masih dibawah pukul 22.00 notif area resto lagi sepi driver padahal di sepanjang jalan banyak driver yg mangkal	⭐⭐⭐	0.962
Pembayaran & GoPay Later	Kenapa biaya jasa aplikasi mahal sekali setiap kali transaksi dikenakan biaya jasa aplikasi Rp 5000 menurut saya mahal banget berasa percuma banget ada promo	⭐	0.958

4. KESIMPULAN

Penelitian ini berhasil menerapkan topic modeling berbasis Latent Dirichlet Allocation (LDA) pada 30.000 ulasan pengguna aplikasi Gojek dari Google Play Store. Dari proses analisis, diperoleh lima kesimpulan utama berikut:

- Pipeline preprocessing teks berbahasa Indonesia yang mencakup penghapusan stopwords dengan kamus Sastrawi+kustom (867 kata) dan stemming berhasil mengurangi noise secara signifikan, terbukti dari perubahan WordCloud sebelum dan sesudah preprocessing.
- Model LDA dengan K=5 dipilih berdasarkan pertimbangan domain-driven karena tidak ditemukannya elbow yang jelas pada grafik perplexity, menghasilkan topik-topik yang kohesif dan dapat diinterpretasi dengan baik.
- Lima topik yang berhasil diidentifikasi adalah: (1) Promo & Diskon (18,4%), (2) Masalah Akun & GoPay (20,6%), (3) Kepuasan Layanan (18,7%), (4) Layanan GoFood & Driver (26,7%), dan (5) Pembayaran & GoPay Later (15,5%).
- Layanan GoFood & Driver merupakan topik yang paling banyak dibicarakan pengguna (26,7%), dan bersama Masalah Akun & GoPay menjadi sumber keluhan terbesar pada ulasan bintang 1.
- Analisis heatmap mengungkap bahwa Topik Kepuasan Layanan sangat berkorelasi dengan ulasan bintang 5 (40,0%), menjadikannya indikator kuat kepuasan pengguna.

Penelitian ini menunjukkan efektivitas LDA sebagai alat analisis ulasan aplikasi berbahasa Indonesia. Untuk penelitian selanjutnya, dapat dipertimbangkan penggunaan model berbasis transformer seperti BERTopic yang mampu menangkap konteks semantik lebih dalam, serta analisis temporal untuk melacak perubahan topik antar versi aplikasi.

DAFTAR PUSTAKA

[1] M. Wankhade, A. C. S. Rao, and C. Kulkarni, "A survey on sentiment analysis methods, applications, and challenges," Artificial Intelligence Review, vol. 55, pp. 5731–5780, 2022.

[2] D. M. Blei, A. Y. Ng, and M. I. Jordan, "Latent Dirichlet Allocation," Journal of Machine Learning Research, vol. 3, pp. 993–1022, Jan. 2003.

[3] A. Tala, "A Study of Stemming Effects on Information Retrieval in Bahasa Indonesia," M.S. thesis, Universiteit van Amsterdam, 2003.

[4] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.

[5] U. Chauhan and A. Shah, "Topic Modeling using Latent Dirichlet Allocation: A Survey," ACM Computing Surveys, vol. 54, no. 7, pp. 1–35, 2021.

[6] M. Grootendorst, "BERTopic: Neural topic modeling with a class-based TF-IDF procedure," arXiv preprint arXiv:2203.05794, 2022.